

Modelo para la detección de avalanchas en secuencias de vídeo :Caso Laguna Palcacocha

Milwart R. Calizaya Bobadilla

10 de septiembre de 2019

Capítulo 1

Introducción

Las avalanchas junto con otros fenómenos naturales como tsunamis, terremotos, etc. son los más destructivos y ocurren en Perú y el mundo y han causado daños materiales y vidas humanas. Si bien existen sensores como LiDAR (Light Detection And Ranging), y Radar (Radio Detection And Ranging), que se utilizaron en estudio de nieve, detección de avalanchas, etc. existen otros sensores acústicos, infrasonido y de fibra óptica que si bien no estudian directamente avalanchas se pueden aplicar a otro tipo de movimientos de masa entre ellos avalanchas, por otro lado se ha masificado el uso de cámaras para video vigilancia, en investigación el uso de videos se ha visto limitado a entornos controlados, ya que en entornos reales se tiene problemas como la iluminación, resolución, movimiento, etc. la presente investigación se centra en el desarrollo de un modelo para la detección de avalanchas en secuencias de video en la laguna Palcacocha.

1.1. Justificación

El Perú tiene un largo historial de eventos desastrosos sobre todo en la cordillera blanca, los eventos más recordados y catastróficos en Perú ocurrieron en 1962, 1970 donde se desprendió el pico norte del nevado Huascarán provocando una avalancha en Yungay y alrededor de 6000 a 7000 muertes (Evans y cols., 2009) y otro evento de gran magnitud fue el evento ocurrido en Huaraz el 13 de diciembre de 1941, donde fallecieron 1800 personas (Wegner Steven, 2014) a causa del desprendimiento de un enorme glaciar en la laguna Palcacocha; en ambos casos los eventos sucedieron a causa de avalanchas, es por eso que la detección de avalanchas es crucial para personas y poblaciones. más aún por los efectos del cambio climático que derriten masas de hielo en los polos y la cordillera, lo que produce mayor riesgo de avalanchas. La presente investigación pretende con el modelo desarrollado ayudar mitigar el riesgo frente a una inminente avalancha.

1.1.1. Lugar de Estudio: Laguna Palcacocha

El presente trabajo trata de resolver el problema de la detección de avalanchas en la laguna Palcacocha que se encuentra ubicada en la ciudad de Huaraz (Figura 1), capital del departamento de Ancash, que tiene una población de 140 mil habitantes que históricamente sufrió eventos extremos como el aluvión del 13 de diciembre de 1941, a causa de un desprendimiento de un enorme glaciar en la laguna Palcacocha que esta localizada en $9^{\circ}23'S$, $77^{\circ}22'W$, sobre los 4562

m.s.m.m., perteneciente al distrito de Independencia, Provincia de Huaraz, departamento de Ancash (Somos-Valenzuela, Chisolm, Rivas, Portocarrero, y McKinney, 2016). Tiene un volumen de alrededor de 17.4 millones de m³ y aunque existe un gran interés en los trabajos de prevención ante un potencial aluvi3n debido al desborde de la laguna Palcacocha.

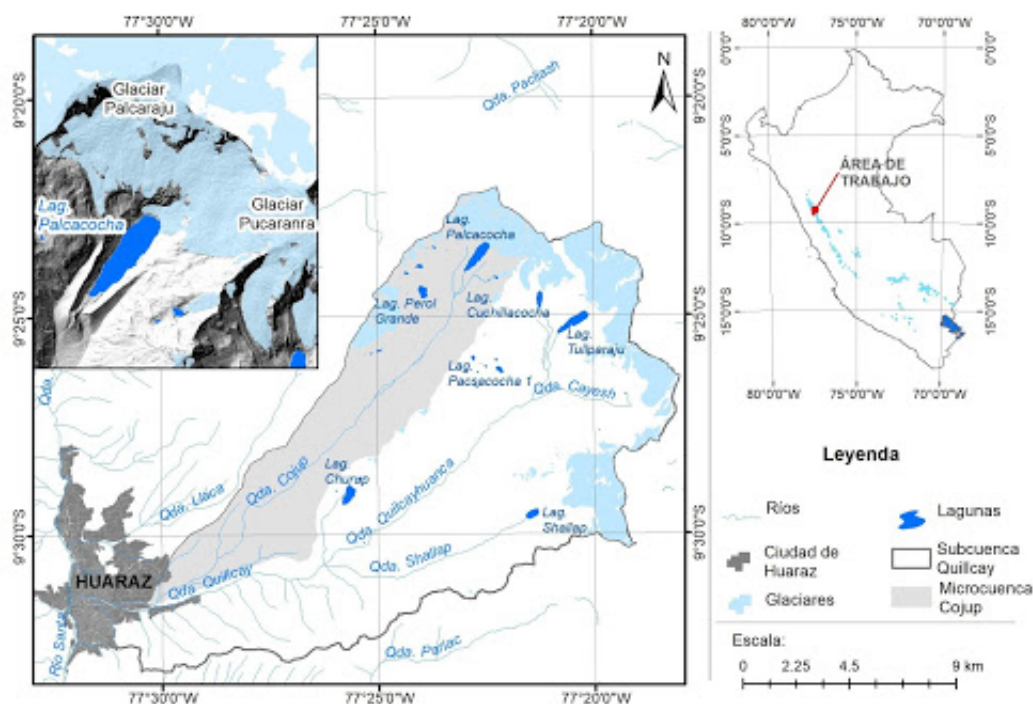


Figura 1.1: Palcacocha

1.2. Relevancia

Teniendo en cuenta que los sensores activos como LiDAR (Light Detection And Ranging), y Radar (Radio Detection And Ranging), etc. se usan para la detección de avalanchas, movimientos de masa, etc. y son precisos pero costosos y los sensores pasivos en muchos casos son menos costosos pero se ven limitados por lo peligroso de su implantación, mantenimiento o como en el caso de video que a pesar de que se tiene la información en tiempo real se ven limitados por la iluminación, resolución y condiciones del climáticas, y la presente investigación pretende presentar un modelo para la detección de avalanchas en video no muy costo pero eficiente. En cuanto a otras investigaciones no se encontraron trabajos relacionados a detección de avalanchas en video.

1.3. Motivación

Se prevee que las avalanchas iran en aumento producto del cambio climático es por eso que hoy resulta importante estudiar su comportamiento, existen muchas técnicas y sensores que pueden ser usados en detección de avalanchas, y estos pueden ser activos o pasivos de acuerdo a como interactúan con el objeto de estudio, los sensores activos como LiDAR (Light Detection And Ranging), y Radar (Radio Detection And Ranging), usan partes específicas del espectro electromagnético, miden la radiación emitida por la superficie (Eckerstorfer, Bühler, Frauenfelder, y Malnes, 2016), algunas investigaciones usan LiDAR (Deems, Painter, y Finnegan, 2013) y otras Radar (Schimmel, Hübl, Koschuch, y Reiweger, 2017; Long, Brummer, y Nalli, 2016); a pesar de que estos sensores son buenos para la noche (Long y cols., 2016), son muy costosos y los pasivos usan el reflejo de la luz solar del espectro electromagnético visible o infra rojo cercano (Fuchs, Keiler, y Sokratov, 2019), con los avances tecnológicos y la reducción de costos, el uso de estos, especialmente cámaras se ha extendido y se usan cada vez con mas frecuencia en el área de visión computacional (Jesus y Talavera, 2018).y con inteligencia artificial se usan para monitorizar, detectar ciertos eventos como la detección de fuego (Muhammad y cols., 2019), etc. si bien en estos trabajos el uso de videos se ve limitado a la iluminación diurna representan una opción de bajo costo con buenos resultados en tareas específicas.

1.4. Objetivo general

Proponer un Modelo para la detección de avalanchas en secuencias de video

1.5. Objetivos específicos

- Analizar algoritmos de pre procesamiento de videos.
- Analizar algoritmos de flujo óptico.
- Proponer un nuevo esquema usando inteligencia artificial para detectar avalanchas en secuencias de video.
- Evaluar y comparar el rendimiento del detector de avalanchas con técnicas propuestas en secuencias de video.

Capítulo 2

Marco Conceptual

2.1. Descriptores visuales

2.1.1. Descriptores Basados en Apariencia

Patrones Locales Binarios (LBP)

Es un descriptor visual simple pero muy eficiente usado para la clasificación de texturas. LBP puede ser visto como un enfoque que unifica la estadística divergente tradicional y el análisis de modelos estructurales de textura. Su propiedad más importante es que este descriptor es invariante a cambios en los niveles de los colores en escala de grises producidos por cambios en la iluminación, lo que lo convierte en un descriptor ideal para aplicaciones reales. Al ser un descriptor simple puede llegar a procesar imágenes en tiempo real. El descriptor original de LBP fue presentado por Ojala. En este trabajo el descriptor trabajaba sobre una vecindad cercana a un píxel central de 3x3, y el valor central era utilizado como un umbral.




Figura 2.1: vecinos en Lbp




Figura 2.2: Ejemplo de Lbp

HOG

El histograma de gradientes orientados (HOG) es un descriptor de características que se utiliza en visión por computador y en el procesamiento de imágenes para la detección de objetos. tiene dos pasos muy marcados, divide la imagen en un numero definido de celdas y para cada celda obtiene un histograma de la orientación de cada celda en el segundo paso se calcula los histogramas para todas las celdas luego se combinan para tener la representación global de la imagen en forma de vector de características.




Figura 2.3: Hog

2.1.2. Descriptores Basados en Movimiento

Flujo Óptico

El flujo óptico puede ser definido como el movimiento aparente de los patrones de intensidad en una imagen. La palabra aparente indica que el movimiento espacial de los objetos (campo de movimiento) puede coincidir o no con el flujo estimado. No obstante, en situaciones en las cuales el movimiento de los objetos implica un movimiento de sus patrones de intensidad en el plano de la imagen, el flujo óptico puede relacionarse directamente con el movimiento de los objetos en la escena

Los algoritmos de flujo óptico tratan de estimar el desplazamiento de un pixel a través de dos consecutivos fotogramas calculando el ángulo de la dirección de su desplazamiento. El resultado que se obtiene es la cantidad de desplazamiento de un pixel en el eje coordenado X y Y. Dentro de las técnicas de flujo óptico ampliamente utilizadas tenemos:

- Lucas - Kanade

- Horn - Shunck
- Gunnar Farneback




Figura 2.4: Flujo optico

2.2. Clasificadores

2.2.1. Cascadas de Haar

Propuesto por Viola-Jones, las cascadas de Haar pueden ser definidas básicamente como un conjunto de regiones rectangulares de sumas a los cuales se les resta otras regiones, las cuales pueden estar presentes en cualquier posición y escala dentro de una imagen. Estas restas son analizadas por clasificadores en cascada, los cuales son un conjunto de clasificadores débiles que trabajando en conjunto para forman un clasificador fuerte, el cual decide qué características son relevantes y cuales tienen que ser rechazadas.

2.2.2. Red Neuronal Convolutiva

La arquitectura de una Red Neuronal Convolutiva está compuesta por diferentes capas que transforma la entrada en un conjunto de salida.




Figura 2.5: Arquitectura de una red neuronal convolutiva

Capa de convolución es el núcleo principal de la construcción de una Red Neuronal Convolutiva. La capa de convolución consiste en un conjunto de neuronas que conecta regiones pequeñas de la entrada con una capa anterior. Estas regiones son llamadas filtros los cuales pueden variar de tamaño.

La función de Pooling reduce progresivamente el tamaño espacial de la representación con el objetivo de reducir la cantidad de parámetros y cálculos en la Red. Existen varias funciones

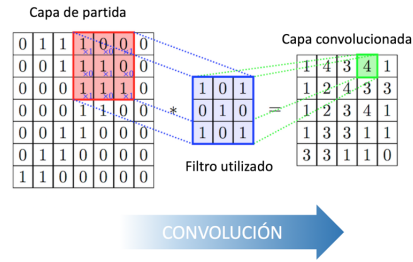


Figura 2.6: Convolucion




Figura 2.7: poolingl

2.2.3. Support Vector Machine (SVM)

Está basado en la teoría de aprendizaje propuesto por SVMs son clasificadores lineales, y determinan un límite de decisión mediante un hiperplano. Como puede existir un límite infinito de hiperplanos, uno se puede preguntar cuál de estos hiperplanos es el óptimo en términos de generalizar el clasificador. Por este motivo los SVMs son construidos de tal manera que maximicen la distancia para el conjunto de datos de entrenamiento más cercano de ambas clases.




Figura 2.8: Support Vector Machine

2.3. Evaluación

2.3.1. Evaluación del clasificador

Matriz de confusión

Matriz de confusión es una herramienta que permite la visualización del desempeño de un algoritmo que se emplea en aprendizaje supervisado. Cada columna de la matriz representa el

número de predicciones de cada clase, mientras que cada fila representa a las instancias en la clase real

		Predicted class	
		<i>P</i>	<i>N</i>
Actual Class	<i>P</i>	True Positives (TP)	False Negatives (FN)
	<i>N</i>	False Positives (FP)	True Negatives (TN)

Figura 2.9: Matriz de confusionl

2.3.2. Evaluación del detector

F-score

La evaluación del rendimiento del detector será mediante F-score, para eso se tiene que calcular previamente, los falsos positivos, reales positivos, falsos negativos, reales negativos.

$$\text{Precision} = \frac{\text{True Positive}}{\text{True Positive} + \text{False Positive}}$$

$$\text{Recall} = \frac{\text{True Positive}}{\text{True Positive} + \text{False Negative}}$$

Figura 2.10: Precision y recall

The F-score is the Harmonic mean of Precision and Recall.

$$F = \frac{2}{\frac{1}{\text{Recall}} + \frac{1}{\text{Precision}}}$$

Alternatively

$$F = 2 \times \frac{\text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}}$$

Figura 2.11: F-Score

Capítulo 3

Revisión Bibliográfica

3.1. Antecedentes del proyecto

Durante décadas no se ha avanzado en la detección de avalanchas y sobre todo con técnicas en videos (Christiansen, 2001), y uno de los primeros trabajos en los que se usa fotografía para estudiar el comportamiento de la nieve (Christiansen, 2001); existen otros trabajos para monitorizar deslizamientos de avalanchas con fotografías estos trabajos tratan de monitorizar el desplazamiento mediante el conteo de píxeles negros en fotografías continuas generalmente tomadas en un intervalo de 15 minutos (Thesis, 2014; A. V. Herwijnen y Simenhois, 2012; A. Herwijnen y cols., 2013); también (A. V. Herwijnen y Simenhois, 2012) recomienda, Primero: que el ángulo de visión de la cámara y la pendiente deben de estar lo mas cerca posible a 90 grados; Segundo: La cámara deberá de tener buen acercamiento en el área de interés para obtener mejores datos; Tercero: el intervalo entre imágenes deberían de tener como máximo ya que las avalanchas surgen rápidamente después de las grietas; por lo tanto se entiende que un monitoreo en tiempo real seria lo ideal no solamente para monitorizar grietas; si no también avalanchas en ese sentido el uso de videos para estudiar eventos anómalos se ha masificado, existen investigaciones que hacen uso de video para el estudio de avalanchas (Akitaya, 1980; Nishimura y cols., 1993); sin embargo solo llegan a registrar estos eventos mas no a detectarlos, considerando los avances tecnológicos, particularmente en inteligencia artificial, se tienen trabajos en pronostico y detección, (Singh y Ganju, 2008) hace uso de redes neuronales artificiales (ANN) y como parámetros de entrada, temperatura del aire, temperatura de la superficie de la nieve, velocidad del viento, etc. los investigadores indican de que ningún modelo puede imitar completamente el método de análisis de un experto, pero con los avances en inteligencia artificial lo modelos están demostrando que son confiables, en detección de eventos en video por ejemplo (Arceda, 2015). presenta un método para la detección en tiempo real de acciones violentas en secuencias de video con Violent Flow (ViF) y horn-schunk, donde vif es un descriptor y horn-schunk es un algoritmo de flujo óptico, esta investigación concluye que el método vif horn-shunk tiene buen desempeño reduciendo el tiempo de procesamiento, en otros casos se tiene investigaciones aplicadas a la detección de desastres como es el caso de (Muhammad y cols., 2019), que en su investigación comentan las bondades de las redes neuronales convolucionales (CNN) en su desempeño y lo importante que sería su aplicación y reducir el impacto ecológico y social, al

mismo tiempo comentan lo costoso computacionalmente que es utilizarlos es por eso que ellos hace uso de una red SqueezeNet (modelo de red neuronal), respecto detección de avalanchas en video no se encontraron investigaciones.

Capítulo 4

Propuesta

4.1. Base de datos

Se tiene una registro en video del estado de la laguna Palcacocha de Marzo a Julio de 2019, que se utilizaran para probar el modelo propuesto.

4.2. Experimentos

Luego de implementado los diferentes sistemas de adquisición de datos, se extraerán secuencias de video que superen el umbral de movimiento; previamente se realizara el preprocesamiento de video donde se quitara el ruido producido por lluvias, neblina y el movimiento de la cámara generada por el viento.

Luego se procederá a la extracción de características de los puntos de interés, las lenguas glaciares y las secciones del posible recorrido de la avalancha, se propone experimentar con descriptores basados en apariencia LBP, HOG (Local Binary patterns , Histogram Oriented Gradient) y descriptores basados en movimiento HOF, HOOOF, HOFG (Histogram Oriented Flow, Histogram of Oriented Optical Flow, Histogram of optical flow Gradients), y técnicas complementarias de flujo óptico como el algoritmo Gunnar Farnebäck, Horn - Shunck, Lucas - Kanade y el descriptor de Flujo Violento; operadores morfológicos (para remover ruido y separar elementos); se probará también diferentes clasificadores, entre ellos Support Vector Machine, cascadas de haar, Redes neuronales convolucionales.

Se usará matrices de confusión para la evaluación, comparación del desempeño de los clasificadores, y para la evaluación del detector se utilizara F-score, seleccionando el mejor subconjunto. Las salidas de los modelos de detección de movimiento, se determinará la sensibilidad y precisión. Para finalmente determinar los modelos apropiados al caso estudiado.

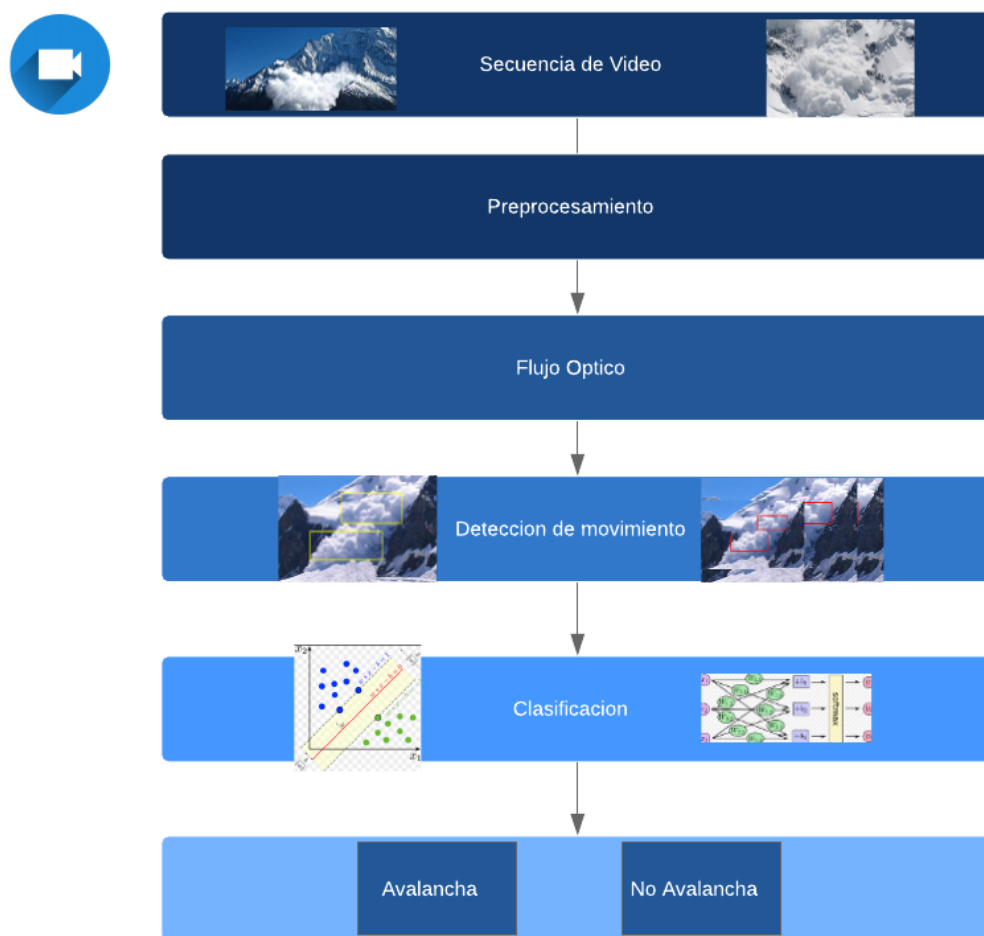


Figura 4.1: Propuesta

Capítulo 5

Cronograma de Actividades

Actividad	Meses											
Revisión bibliográfica	X	X	X									
Análisis del estado del Arte	X	X	X									
Análisis sobre técnicas de captura de datos	X	X										
Instalación de equipos de captura de datos		X										
Base de datos		X	X									
Extracción de vídeos de Avalancha		X	X									
Extracción manual de imágenes		X	X									
Preprocesamiento			X	X								
Análisis sobre algoritmos de preprocesamiento de videos			X	X								
Implementación de algoritmos de preprocesamiento de videos			X	X								
Evaluación, comparación de algoritmos de preprocesamiento				X								
Flujo Óptico					X	X						
Análisis de algoritmos de flujo óptico					X	X						
Implementación de algoritmos de flujo óptico					X	X						
Evaluación de Algoritmos de Flujo óptico					X	X						
Inteligencia Artificial							X	X	X			
Análisis sobre algoritmos de Inteligencia artificial							X	X				
Implementación de algoritmos de Inteligencia artificial							X	X	X			
Evaluación de algoritmos de inteligencia artificial							X	X	X			
comparación de técnicas implementadas								X	X			
Análisis de Resultados										X	X	
Documentación de resultados										X	X	
Análisis estadístico de resultados											X	X
Presentación de resultados												X

Figura 5.1: Cronograma de actividades

Referencias

- Akitaya, E. (1980). Short Notes Observations of Ground Avalanches With a . , 26(94).
- Arceda, M. (2015). Universidad Nacional de San Agustín Tesis de Maestría Detección de acciones violentas en secuencias de video Gutiérrez.
- Bessason, B., Eiríksson, G., Thórarinnsson, Ó., Thórarinnsson, A., y Einarsson, S. (2007). Automatic detection of avalanches and debris flows by seismic methods. *Journal of Glaciology*, 53(182), 461–472.
- Christiansen, H. H. (2001). Snow-cover depth, distribution and duration data from Northeast Greenland obtained by continuous automatic digital photography. *Annals of Glaciology*, 32, 102–108.
- Deems, J. S., Painter, T. H., y Finnegan, D. C. (2013). Lidar measurement of snow depth : a review. , 59(215), 467–479. doi: 10.3189/2013JoG12J154
- Eckerstorfer, M., Bühler, Y., Frauenfelder, R., y Malnes, E. (2016). Remote sensing of snow avalanches: Recent advances, potential, and limitations. *Cold Regions Science and Technology*, 121, 126–140. Descargado de <http://dx.doi.org/10.1016/j.coldregions.2015.11.001> doi: 10.1016/j.coldregions.2015.11.001
- Evans, S. G., Bishop, N. F., Fidel Smoll, L., Valderrama Murillo, P., Delaney, K. B., y Oliver-Smith, A. (2009). A re-examination of the mechanism and human impact of catastrophic mass flows originating on Nevado Huascarán, Cordillera Blanca, Peru in 1962 and 1970. *Engineering Geology*, 108(1-2), 96–118. Descargado de <http://dx.doi.org/10.1016/j.enggeo.2009.06.020> doi: 10.1016/j.enggeo.2009.06.020
- Fuchs, S., Keiler, M., y Sokratov, S. (2019). Snow avalanches. , 369–390. Descargado de <http://dx.doi.org/10.1016/B978-0-12-814899-0.00015-8> doi: 10.1016/B978-0-12-814899-0.00015-8
- Herwijnen, A., Berthod, N., Simenhois, R., Mitterer, C., Berthod, N., Simenhois, R., y Mitterer, C. (2013). Using Time-Lapse Photography in Avalanche Research. *International Snow Science Workshop Grenoble -Chamonix Mont-Blanc - October 07-11, 2013*, 950–954. Descargado de <http://arc.lib.montana.edu/snow-science/item.php?id=1774{ }5Cnhttp://arc.lib.montana.edu/snow-science/objects/ISSW13{ }paper{ }02-16.pdf>
- Herwijnen, A. V., y Simenhois, R. (2012). Monitoring glide avalanches using time-lapse photography. *International Snow Science Workshop*, 899–903.
- Jesus, R., y Talavera, C. (2018). Modelo para la detección de rostros en secuencias de Video con Baja Calidad. *Universidad Nacional de San Agustín*. Descargado de <http://repositorio.unsa.edu.pe/handle/UNSA/6453>

- Long, D. G., Brummer, A., y Nalli, B. (2016). Microwave Radar System for Detecting Avalanches International Snow Science Workshop 2016 in Breckenridge , Co. (1), 316–321.
- Muhammad, K., Ahmad, J., Lv, Z., Bellavista, P., Yang, P., y Baik, S. W. (2019). Efficient Deep CNN-Based Fire Detection and Localization in Video Surveillance Applications. *IEEE Transactions on Systems, Man, and Cybernetics: Systems*, 49(7), 1419–1434. doi: 10.1109/TSMC.2018.2830099
- Nishimura, K., Maeno, N., Sandersen, F., Kristensen, K., Norem, H., y Lied, K. (1993). Observations of the dynamic structure of snow avalanches. *Annals of Glaciology*, 18, 313–316. doi: 10.3189/s026030550001171x
- Schimmel, A., Hübl, J., Koschuch, R., y Reiweger, I. (2017). Automatic detection of avalanches: evaluation of three different approaches. *Natural Hazards*, 87(1), 83–102. doi: 10.1007/s11069-017-2754-1
- Singh, A., y Ganju, A. (2008). Artificial Neural Networks for snow avalanche forecasting in Indian Himalaya. *12th International Conference on Computer Methods and Advances in Geomechanics 2008*, 3(July).
- Somos-Valenzuela, M. A., Chisolm, R. E., Rivas, D. S., Portocarrero, C., y McKinney, D. C. (2016). Modeling a glacial lake outburst flood process chain: The case of Lake Palcacocha and Huaraz, Peru. *Hydrology and Earth System Sciences*, 20(6), 2519–2543. doi: 10.5194/hess-20-2519-2016
- Thesis, M. (2014). TIME-LAPSE PHOTOGRAPHY. (March).
- Wegner Steven. (2014). Lo que el agua se llevó. , 83.